



Universidad de
La Sabana

Acreditación
Institucional
de Alta Calidad

10
años

LABORATORIO DE GOBIERNO

Modelos predictivos - Clínica de la Universidad de la Sabana

Orgullosamente
UniSabana

OBJETIVO

Diseñar herramientas que permitan a la Clínica Universidad de La Sabana aprovechar de manera óptima sus recursos de datos existentes, con el fin de mejorar **la toma de decisiones tanto operativas como estratégicas** mediante el uso de **analítica predictiva**.



¿Qué hicimos?



Desarrollar **tres modelos predictivos**:

1. Proyección semanal del número de pacientes.
2. Estimación semanal de la facturación.
3. Georreferenciación de pacientes proyectados.



¿Cómo lo hicimos?

1

Tomando información histórica

Para entrenar más de 800 modelos con distintos parámetros a través de un proceso de **Grid Search**.

2

Usando métricas de *Accuracy*

Para encontrar **combinaciones eficientes** de parámetros que produzcan predicciones acertadas.

3

Testeando modelos

Funciones y código para poderlo integrar a la **Suite** existente de manejo de datos.

Resultados preliminares

1. Machine Learning para la predicción de número de pacientes semanales

Exploratory Data Analysis





Se usaron datos
históricos de
**facturación desde
enero del 2023.**




Se realizó un **estimado
histórico del número de
pacientes** que causaron
facturación en la Clínica.




Se usaron dos
algoritmos avanzados
de Forecasting;
SARIMAX y Prophet

Dos momentos de tendencia de largo plazo:

- Una tendencia a la baja hasta enero del 2024
- Caídas mayores a lo previsto para los meses de abril y mayo





Se observa una estacionalidad de 52 semanas en la serie analizada.

Por tipo de seguro médico




Descomposición de la serie de tiempo - Medicina prepagada

Serie original (Seguro médico)



Tendencia



Estacionalidad




Residuo



Descomposición de la serie de tiempo - Seguro médico

Serie original (Seguro médico)




Tendencia



Estacionalidad



Residuo







Se encontró un modelo particular que tiene el menor error posible para pacientes de **Seguro Médico** y otro para **Medicina Prepagada**.




Los modelos tienen en cuenta: tendencias de largo plazo, estacionalidades relevantes, el efecto de festivos y fines de semana, al igual que choques aleatorios no predecibles. Todo con un **intervalo de confianza del 95%**.



- Para los pacientes de **Medicina prepagada** encontramos dos modelos prometedores, uno con **error MAE de alrededor del 12%**



- Para los pacientes de **Seguro Médico** encontramos dos modelos prometedores, uno con **error MAE de alrededor del 11%**.



Hemos convertido este código en una herramienta web donde se pueden testear distintos modelos, estudiar y comparar los resultados de los modelos.


2. Proceso de Auto Machine Learning para la predicción de facturación semanal




Se usó una estructura muy similar al modelo anterior, pero, en este caso **se probaron más de 2.000 combinaciones de parámetros** para encontrar el modelo con mayor capacidad predictiva.



Se usaron dos **algoritmos** avanzados de Forecasting; **SARIMAX y Prophet**, comparados con un modelo Naïve, para asegurar que esta propuesta es más eficiente que usar la intuición.



En el caso de **Seguro médico**, encontramos que, el modelo **SARIMAX reduce el error en un 25%** respecto a usar el promedio como predicción constante.



En el caso de **Medicina prepagada**, encontramos que, el modelo SARIMAX reduce el **error en un 20%** respecto a usar el promedio como predicción constante.

3. Georeferenciación de pacientes únicos




Utilizando un API de Google, al igual que análisis de texto, pudimos realizar un proceso de codificación de información geográfico.




Con este, se pueden asignar latitudes y longitudes a cualquier dirección de un paciente, con un más del 95% de éxito sobre los más de 7.000 pacientes únicos de la clínica en el periodo estudiado.




Con esta georeferenciación, es posible crear mapas de densidad, identificar áreas de influencia de la clínica y definir posibles mercados.



Geolocalizamos a más de 7.000 pacientes de todo el país, encontrando considerables agrupaciones de pacientes de fuera del Área metropolitana de Bogotá



**Realizamos análisis de agrupaciones, encontrando
clústers de pacientes relevantes y espacios de mejora**



Calculamos isocrónas; polígonos que representan el área de influencia ideal de la clínica usando la infraestructura vial.



Existen densas agrupaciones de pacientes en el **nor-orienté de Bogotá y la conurbación Cajicá/Chía** donde cualquier punto de la mancha urbana está a menos de 300 metros de la vivienda de un paciente.

.



Se observan amplios **vacíos de cobertura** en el nor-occidente y centro ampliado de Bogotá: **Suba, Engativá y Teusaquillo**.



Existe una agrupación de territorio de más de 66 Km cuadrados al orienté de la Avenida Suba, **entre calles 34 y 184** donde casi la totalidad del espacio está a menos de 300 metros de la vivienda de uno de los **pacientes de la clínica del último año**.

LABORATORIO DE GOBIERNO



UNIVERSIDAD DE LA SABANA

